Lectura topológica crítica del catálogo de exoplanetas

Un flujo CRISP-DM con Mapper/TDA, imputación y auditoría de sesgo

Proyecto de análisis de exoplanetas

PSCompPars → preparación → Mapper → evaluación crítica → comunicación

Pitch en una frase

Idea central

Usamos Mapper/TDA para construir una lectura topológica crítica del catálogo de exoplanetas: no una taxonomía final, sino un mapa de regiones candidatas auditadas por imputación, sesgo observacional y sensibilidad metodológica.

El valor del proyecto no es solo ver grafos: es decidir cuándo creerles y cuándo tener cautela.

Agenda CRISP-DM

Fase	Pregunta que responde en este proyecto
1. Business Understanding	¿Qué queremos aprender sin sobreprometer?
2. Data Understanding	¿Qué contiene el catálogo y qué sesgos trae?
3. Data Preparation	¿Cómo hacemos una matriz usable y auditable?
4. Modeling	¿Cómo construimos los grafos Mapper?
5. Evaluation	¿Qué grafos son prometedores y cuáles son riesgosos?
6. Deployment/Communication	¿Cómo comunicamos regiones candidatas con cautela?

Fase 1

Business Understanding

Definir el problema, el alcance y lo que no se debe afirmar

Problema: los exoplanetas no forman cajitas limpias

- El catálogo mezcla planetas pequeños, sub-Neptunos, gigantes y órbitas muy distintas.
- Muchas transiciones son graduales, no separaciones perfectas.
- La observación también deja huella: no todos los planetas son igual de detectables.

Riesgo

Una región visible puede reflejar física, sesgo observacional, imputación o una mezcla de las tres.

Pregunta de investigación

Pregunta

¿Puede Mapper revelar regiones estructuradas en variables físicas, orbitales y térmicas, y ayudar a distinguir señal astrofísica plausible de sesgo observacional e incertidumbre por imputación?

Buscamos

- regiones candidatas;
- patrones topológicos;
- evidencia medible para priorizar inspección.

No buscamos

- clases definitivas;
- taxonomía final de planetas;
- probar la topología real del universo.

Fase 2

Data Understanding

Entender el catálogo, sus variables, sus faltantes y sus sesgos

Dataset usado

- Fuente: NASA Exoplanet Archive.
- Tabla: `PSCompPars`.
- Tamaño analizado: 6273 exoplanetas.
- Unidad de análisis: un planeta como punto en un espacio de variables.

Idea central

El dataset es suficientemente rico para explorar estructura, pero no está listo para Mapper sin preparación.

Variables disponibles vs. variables útiles

Decisión

No usamos todas las columnas como coordenadas de Mapper.

- Algunas columnas son identificadores, referencias, incertidumbres o metadata observacional.
- Usarlas todas puede crear geometría dominada por ruido, redundancia o proceso de descubrimiento.
- Usamos vistas pequeñas e interpretables: física, orbital, térmica y conjunta.

Menos variables no significa menos rigor; significa más control interpretativo.

Missingness: el catálogo no está completo

- Mapper requiere una matriz numérica completa.
- Eliminar filas incompletas reduciría demasiado el catálogo.
- La solución fue imputar y después auditar la imputación.

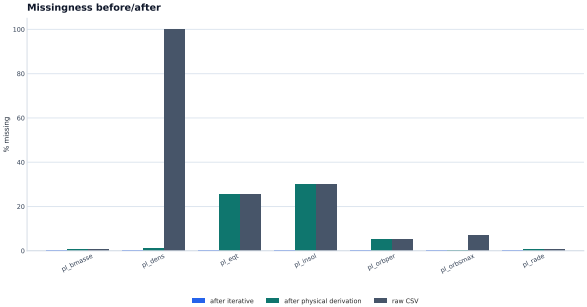

Sesgo observacional como parte del dato

- `discoverymethod`: cómo fue descubierto.
- `disc_year`: cuándo fue descubierto.
- `disc_facility`: con qué instalación o misión.

Uso correcto

Estas variables no construyen el Mapper. Se usan después para preguntar si las regiones están alineadas con el proceso observacional.

Fase 3

Data Preparation

Construir una matriz completa, físicamente razonable y auditable

Imputación principal

- Método principal: `iterative`.
- La imputación permite conservar cobertura del catálogo.
- No se oculta: se registra por planeta, nodo y grafo.

Regla de interpretación

Alta imputación reduce confianza, aunque el grafo sea complejo.

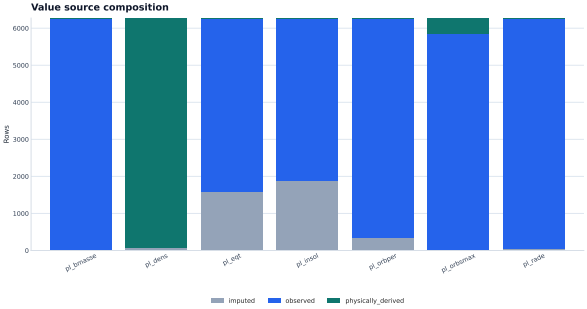

Derivaciones físicas

`pl_dens`

Densidad planetaria derivada a partir de masa y radio cuando fue posible.

`pl_orbsmax`

Semieje mayor derivado desde periodo orbital y masa estelar cuando fue posible.

Lectura

Derivado no significa observado directamente. Por eso `pl_dens` se trata como control cuando aparece junto a masa y radio.

Variables de construcción vs. auditoría

Construyen la geometría

`pl_rade`, `pl_bmasse`, `pl_dens`, `pl_orbper`, `pl_orbsmax`, `pl_insol`, `pl_eqt`.

Auditan la geometría

`discoverymethod`, `disc_year`, `disc_facility`.

Primero construimos regiones con variables físicas/orbitales/térmicas; después preguntamos si esas regiones parecen sesgadas.

Espacios de variables

Espacio	Variables	Lectura
`phys_min`	`pl_rade`, `pl_bmasse`	qué es el planeta
`phys_density`	+ `pl_dens`	control con densidad
`orbital`	`pl_orbper`, `pl_orbsmax`	dónde vive
`thermal`	`pl_insol`, `pl_eqt`	ambiente energético
`orb_thermal`	orbital + térmico	órbita y energía
`joint_no_density`	físico + orbital + térmico	vista conjunta sin densidad
`joint`	joint + `pl_dens`	control conjunto con densidad

Alcance actual

El espacio orbital actual no incluye `pl_orbeccen`; la excentricidad queda como extensión futura.

Fase 4

Modeling

Construir grafos Mapper reproducibles a partir de las vistas preparadas

Mapper en una diapositiva

1. Elegir un espacio de variables.
2. Calcular una lente: principal = pca2.
3. Cubrir la lente con celdas solapadas.
4. Clusterizar localmente dentro de cada celda con DBSCAN.
5. Convertir cada cluster local en nodo.
6. Conectar nodos que comparten planetas.

Mapper produce un grafo de regiones solapadas, no una partición rígida del catálogo.

Qué significa el grafo Mapper

Nodo

Región local de planetas parecidos.

Componente

Zona conectada del mapa.

Arista

Dos nodos comparten al menos un planeta.

Ciclo

Complejidad topológica:

$$\beta_1 = |E| - |V| + \beta_0.$$

Por qué DBSCAN local

- No fija de antemano el número de clusters.
- Funciona bien como clusterizador local dentro de cada celda.
- Permite regiones no perfectamente esféricas.
- Puede dejar puntos aislados como ruido local.

Configuración usada

Parámetro	Valor
`clusterer`	`dbscan`
`min_samples`	4
`eps_percentile`	90.0

Lentes y cover

Lente principal

`pca2`: capa principal de interpretación.

Sensibilidad

`domain` y `density`: lentes para comparar estabilidad.

Cover fijo

`n_cubes=10`, `overlap=0.35`, es decir `cubes10_overlap0p35`.

No se reporta como full grid search de cover.

Modelos generados

- 7 espacios de variables.
- 3 lentes.
- 21 grafos Mapper.
- Cada grafo tiene JSON, nodos, aristas y configuración.

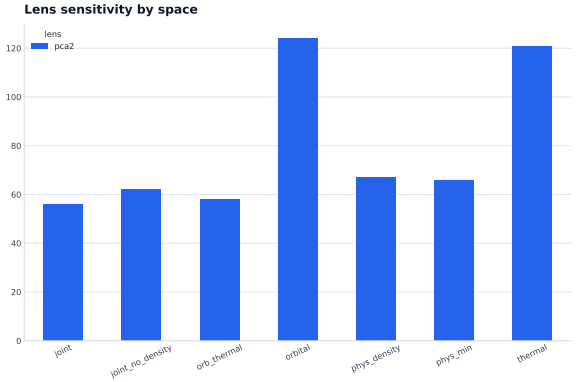

Fase 5

Evaluation

Comparar estructura, confiabilidad y sesgo antes de interpretar

Comparación de grafos

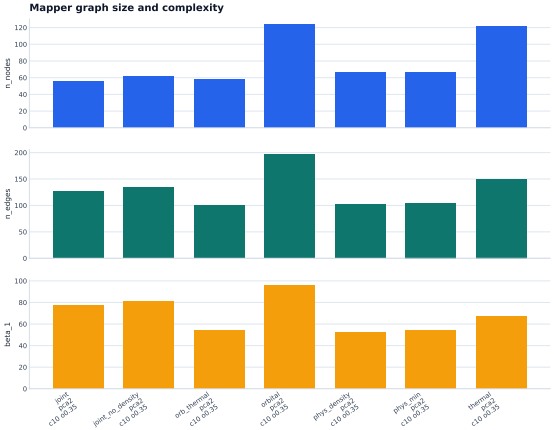

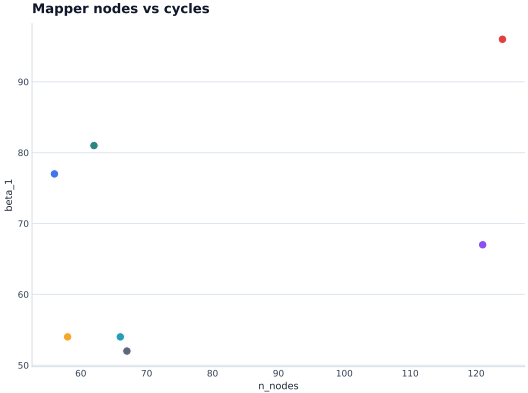

Evaluamos estructura topológica junto con imputación y sesgo, no solo tamaño del grafo.

Resultado principal: grafo orbital

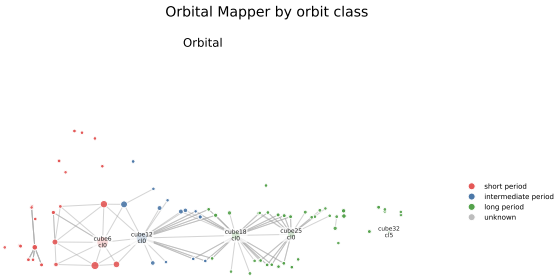

Métrica	Valor
Nodos	124
Aristas	196
β_1	96
Imputación media	0.011

Lectura

Es el candidato principal: alta complejidad y baja imputación.

Físico: referencia limpia

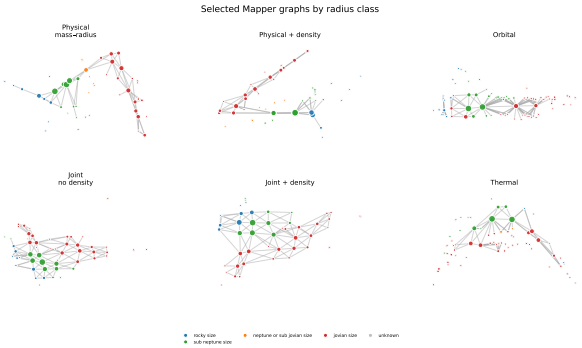

- `phys_min`: masa + radio.
- Lectura más directa de "qué es" el planeta.
- Baja imputación.
- Sirve como referencia frente a espacios más complejos.

Térmico: estructura con cautela

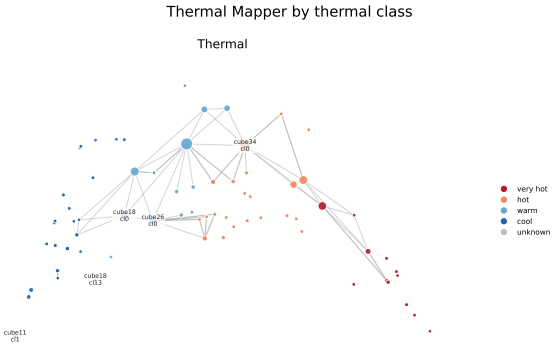

- Usa `pl_insol` y `pl_eqt`.
- Imputación media: 0.588.
- La estructura existe, pero la confianza baja.

Mensaje clave

Complejidad topológica no equivale automáticamente a evidencia astrofísica fuerte.

Densidad como control

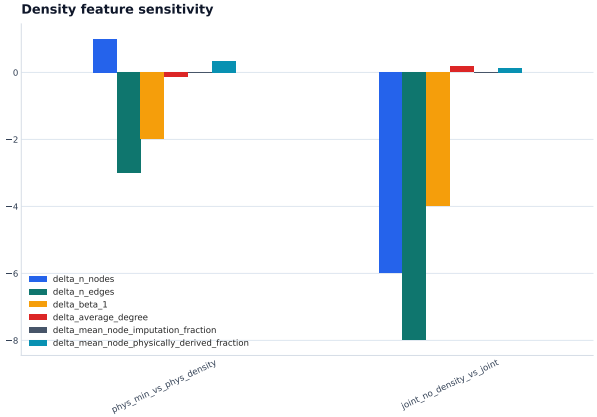

- `pl_dens` aporta información física.
- También depende de masa y radio cuando fue derivada.
- Comparar con/sin densidad mide sensibilidad.

Lectura

La densidad funciona como control metodológico, no como evidencia totalmente independiente.

Auditoría por `discoverymethod`

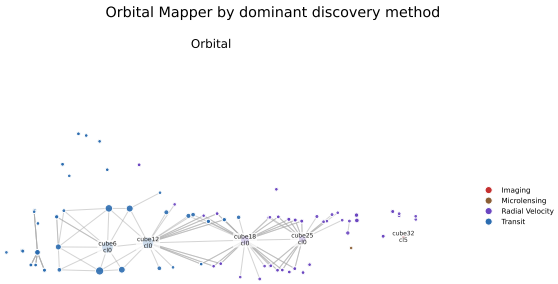

- `discoverymethod` no entra al Mapper.
- Se usa como etiqueta externa.
- Pregunta: ¿los nodos están dominados por un método?

Ejemplo

En orbital, hay regiones dominadas por `Transit`; eso puede mezclar señal orbital y sesgo de detección.

Prueba nula por permutación

Hipótesis nula

Las etiquetas `discoverymethod` no están especialmente asociadas con la estructura Mapper.

Resultado orbital	Valor
Pureza observada por método	0.842
NMI entre nodo y `discoverymethod`	0.254
p empírico	0.001
Permutaciones	1000

El orbital sigue siendo informativo, pero debe leerse como evidencia mixta.

Fase 6

Deployment/Communication

Convertir resultados en una historia defendible y medible

Mapa final de evidencia

La salida comunicable no es “clusters finales”, sino regiones clasificadas por tipo de evidencia.

Categorías finales

Categoría	Interpretación
`physical`	coherencia física/orbital, baja imputación y bajo sesgo
`observational`	dominancia fuerte de método, facility o año
`mixed`	señal interpretable con sesgo observacional relevante
`weak`	alta imputación, región pequeña o evidencia insuficiente

Idea

Estas son categorías de evidencia, no clases planetarias.

Conteos finales

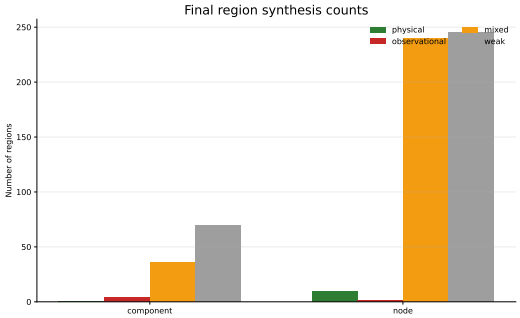

Etiqueta	Nodos	Componentes
`physical`	10	0
`observational`	1	4
`mixed`	240	36
`weak`	245	70

Lectura

Predominan regiones mixtas y débiles. Eso muestra por qué la auditoría era necesaria.

El orbital después de comunicar la evidencia

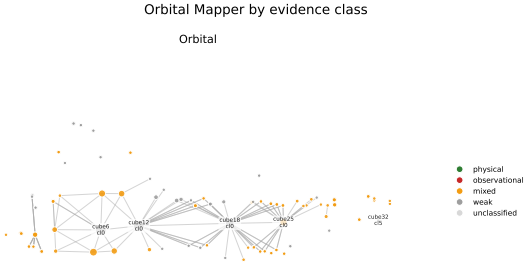

- Es el grafo principal por estructura e imputación baja.
- La auditoría por `discoverymethod` impide leerlo como señal pura.
- Su comunicación correcta es: candidato fuerte, evidencia mixta.

Qué sí afirmamos / qué no afirmamos

Sí afirmamos

- Mapper encontró regiones estructuradas.
- El orbital fue el candidato más informativo.
- La imputación y el sesgo cambian la interpretación.
- Hay regiones para inspección posterior.

No afirmamos

- Clases definitivas de exoplanetas.
- Topología real del universo.
- Causalidad de `discoverymethod`.
- Que más variables siempre sea mejor.

Limitaciones y trabajo futuro

- El cover reconciliado es fijo: `cubes10_overlap0p35`.
- El espacio orbital actual no incluye excentricidad.
- La prueba de permutación mide asociación, no causalidad.
- Las regiones `weak` no deben sobreinterpretarse.
- Futuro: sensibilidad de cover, excentricidad orbital, validación astrofísica externa y revisión por regiones.

Conclusión final

Conclusión defendible

Mapper/TDA es útil para priorizar regiones de inspección en el catálogo de exoplanetas, siempre que sus grafos se lean junto con imputación, sesgo observacional y sensibilidad metodológica.

- El resultado más fuerte es orbital: complejo y con baja imputación.
- La auditoría muestra asociación con `discoverymethod`.
- La conclusión honesta es un mapa de evidencia, no una taxonomía final.

Backup: métricas estandarizadas

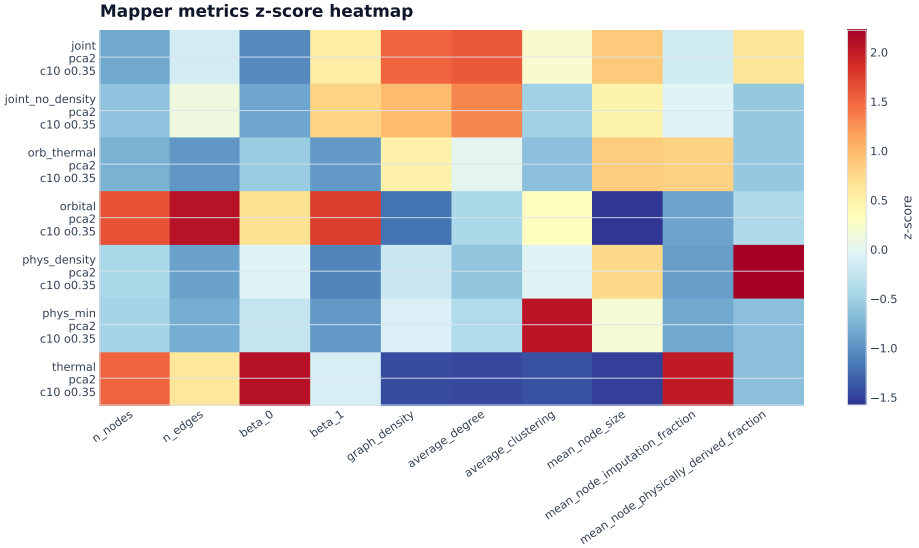

Backup: auditoría de imputación por configuración

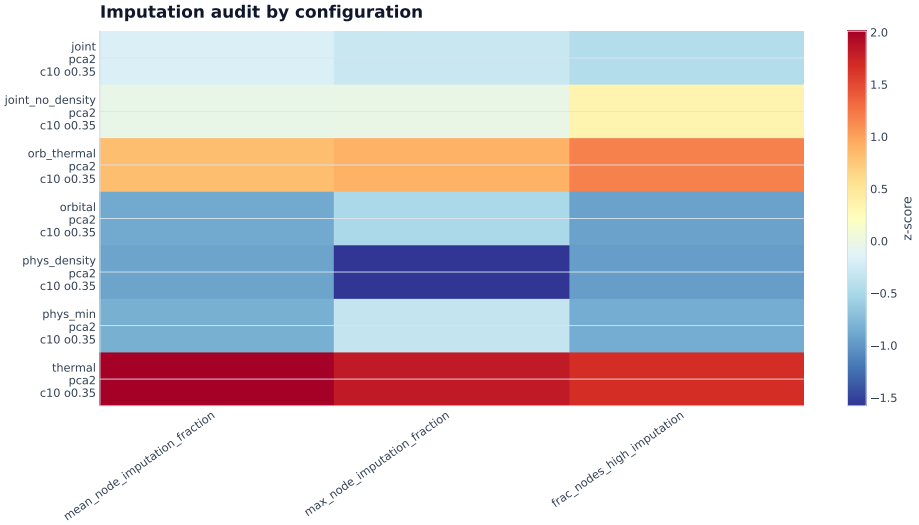
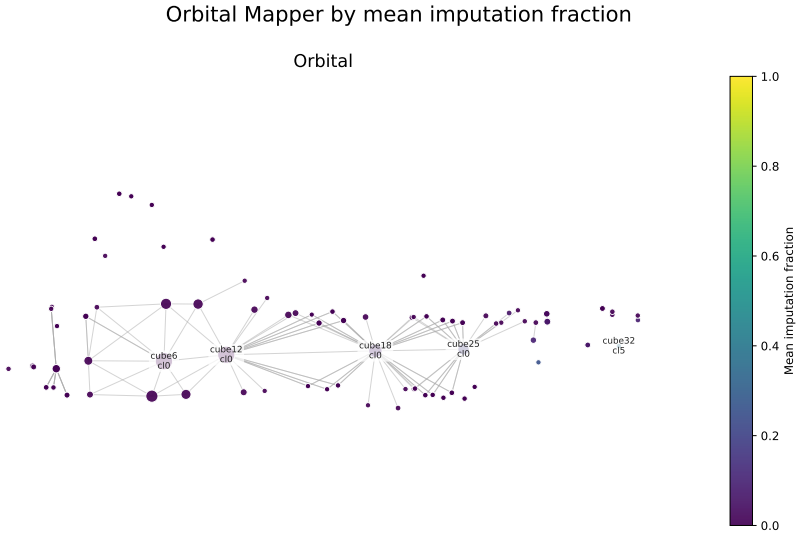
Backup: imputación orbital