Lectura topológica crítica de exoplanetas con Mapper/TDA

Estructura astrofísica plausible, imputación y sesgo observacional

Proyecto de análisis de exoplanetas

NASA Exoplanet Archive PSCompPars → imputación → Mapper → auditorías → síntesis de evidencia

La idea central

Tesis del proyecto

Mapper revela regiones candidatas en el catálogo de exoplanetas, especialmente en el espacio orbital, pero esas regiones no deben interpretarse como clases planetarias definitivas porque están mezcladas con sesgo observacional, imputación y decisiones metodológicas.

La historia completa es:

$$\text{datos} \to \text{espacios de variables} \to \text{Mapper} \to \text{interpretación} \to \text{auditoría de imputación} \to \text{auditoría de sesgo} \to \text{síntesis final}$$

Problema

- Los exoplanetas no forman necesariamente clusters limpios.
- Hay transiciones: tamaño, masa, órbita, temperatura y método de detección se mezclan.
- El catálogo también contiene sesgos: no observamos todos los planetas con la misma facilidad.
- Una visualización bonita no basta: necesitamos saber qué sostiene cada región.

Pregunta

¿Mapper puede revelar regiones estructuradas en variables físicas, orbitales y térmicas, separando señal astrofísica plausible de sesgo e imputación?

Dataset

- Fuente: NASA Exoplanet Archive.
- Tabla usada: `PSCompPars`.
- Tamaño usado: 6273 exoplanetas.
- Método principal de imputación: `iterative`.
- Metadata para auditoría: `discoverymethod`, `disc_year`, `disc_facility`.

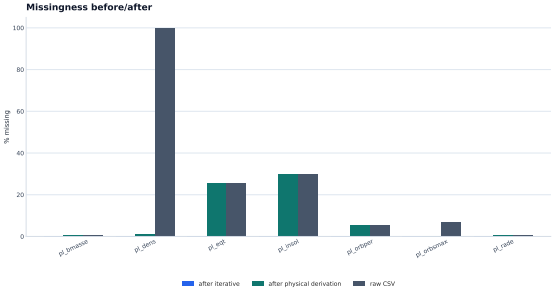

Por qué fue necesaria la imputación

- Mapper necesita una matriz numérica completa.
- Variables térmicas tenían muchos faltantes: `pl_insol` y `pl_eqt`.
- La imputación no se ocultó: se registró por planeta y por nodo.
- Las regiones con alta imputación se interpretan con cautela.

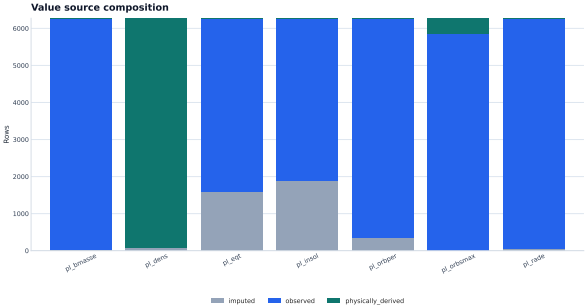

Por qué no usamos todas las variables

Decisión metodológica

El catálogo tiene muchas columnas, pero no todas son variables físicas independientes.

- Muchas columnas son identificadores, referencias, incertidumbres, flags o metadata observacional.
- Usarlas todas podría producir una geometría dominada por ruido, redundancia o proceso de descubrimiento.
- Por eso se construyeron espacios pequeños, interpretables y auditables.

Los espacios son vistas interpretables, no una trampa ni una taxonomía final.

Espacios de variables

Espacio	Variables	Lectura
`phys_min`	`pl_rade`, `pl_bmasse`	qué es el planeta
`phys_density`	+ `pl_dens`	control con densidad derivada
`orbital`	`pl_orbper`, `pl_orbsmax`	dónde vive
`thermal`	`pl_insol`, `pl_eqt`	ambiente energético
`orb_thermal`	orbital + térmico	órbita y energía
`joint_no_density`	físico + orbital + térmico	vista conjunta sin densidad
`joint`	joint + `pl_dens`	control conjunto con densidad

Nota importante

El espacio orbital actual no incluye `pl_orbeccen`; la excentricidad queda como extensión futura.

Qué hace Mapper

- Mapper resume la forma de los datos como un grafo.
- Un nodo es una región local con planetas parecidos.
- Una arista indica que dos nodos comparten planetas.
- Un ciclo β_1 indica complejidad topológica.

$$\beta_1 = |E| - |V| + \beta_0$$

Lentes

La interpretación principal usa `pca2`. `domain` y `density` sirven como sensibilidad.

Cover

Los artefactos reconciliados usan `n_cubes = 10` y `overlap = 0.35`.

Qué se generó realmente

- 21 grafos JSON.
- 21 tablas de nodos.
- 21 tablas de aristas.
- 21 configuraciones.
- 7 espacios de variables $\times$ 3 lentes.

Cuidado

No es un full grid search de `n_cubes` $\times$ `overlap`; es una comparación bajo cover fijo.

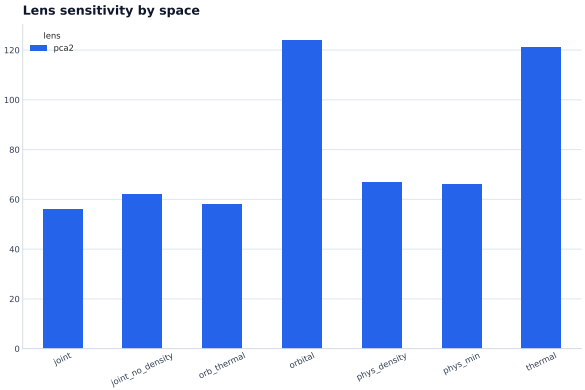

Resultado estructural global

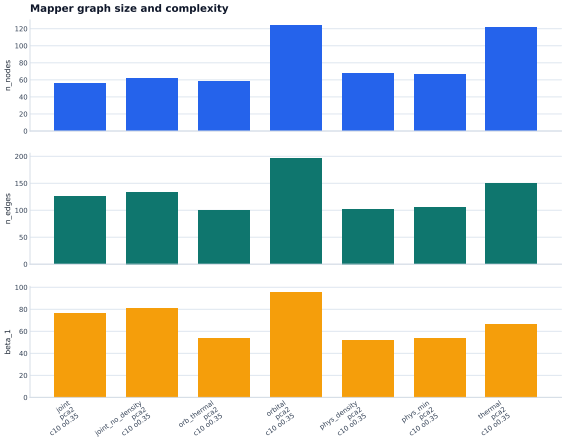

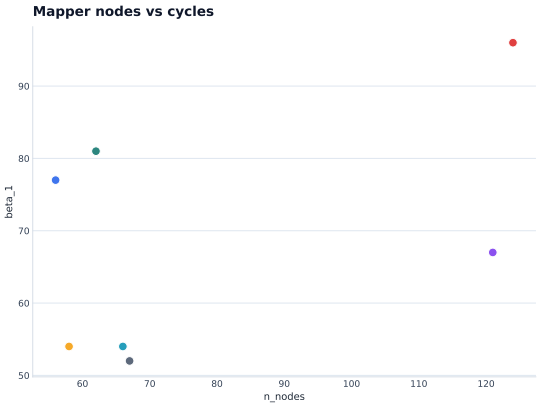

El grafo orbital es el candidato más interesante: 124 nodos, 196 aristas, $\beta_1 = 96$, imputación media 0.011.

El patrón principal: espacio orbital

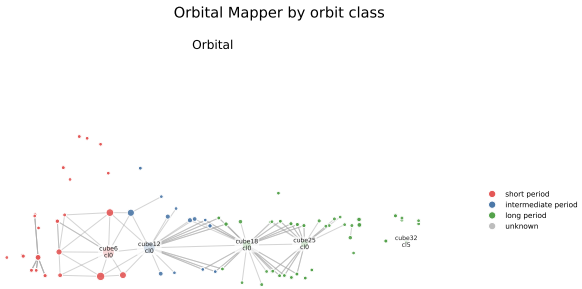

- Usa `pl_orbper` y `pl_orbsmax`.
- Organiza regiones por periodo corto, intermedio y largo.
- Tiene alta complejidad topológica.
- Tiene baja dependencia de imputación.

Lectura prudente

Es un candidato fuerte de inspección, no una prueba de topología real.

Interpretación astrofísica: poblaciones candidatas

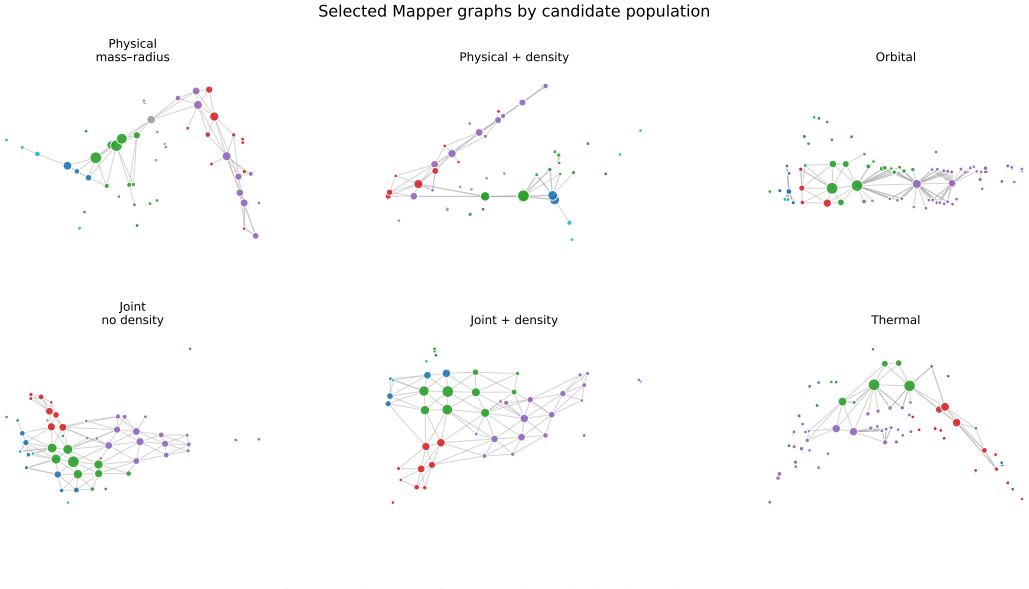

Clases por radio

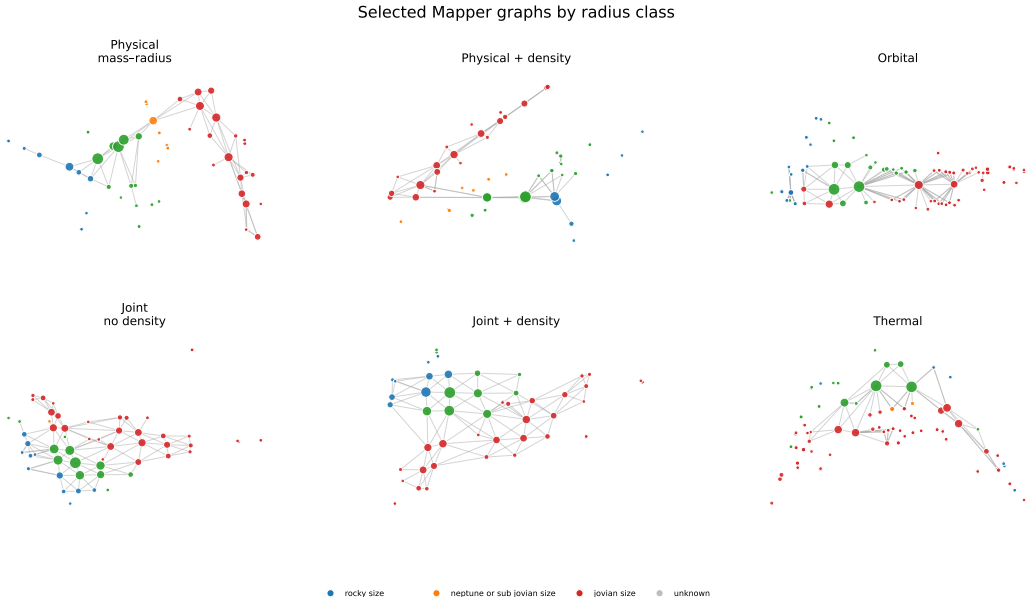

Imputación: qué regiones son más confiables

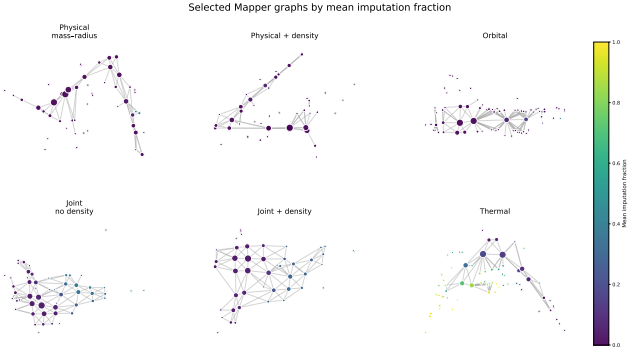

- Físico mínimo: imputación baja, 0.017.
- Orbital: imputación baja, 0.011.
- Joint: imputación moderada, 0.176.
- Térmico: imputación alta, 0.588.

Idea clave

Complejidad topológica no equivale automáticamente a evidencia física fuerte.

El caso térmico: estructura con cautela

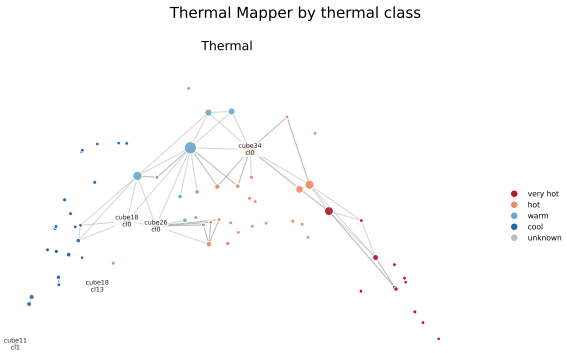

- $\beta_1 = 67$: sí hay estructura.
- Imputación media nodal: 0.588.
- Fracción de nodos con alta imputación: 0.719.

Conclusión

El espacio térmico funciona como advertencia metodológica: se ve estructurado, pero depende mucho de datos completados.

Densidad: control, no evidencia independiente

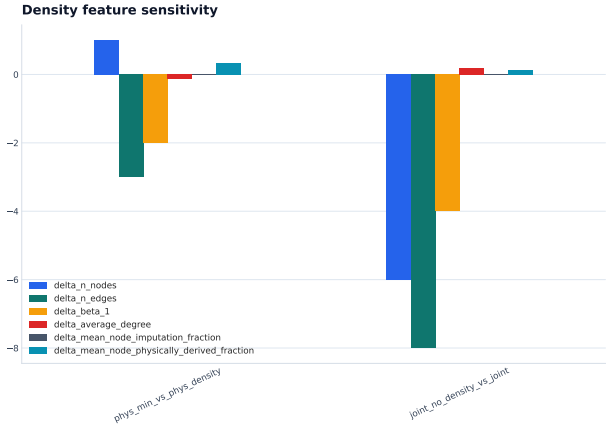

- `pl_dens` fue derivada de masa y radio para muchos planetas.
- Agregar densidad reduce ligeramente la complejidad.
- `phys_min`: $\beta_1 = 54$.
- `phys_density`: $\beta_1 = 52$.
- `joint_no_density`: $\beta_1 = 81$.
- `joint`: $\beta_1 = 77$.

Espacio conjunto

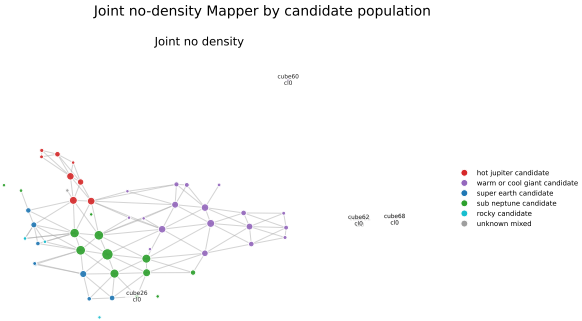

- Integra propiedades físicas, orbitales y térmicas.
- `joint_no_density`: $\beta_1 = 81$.
- Imputación media: 0.176.
- Más informativo que térmico, pero menos limpio que orbital.

Lectura

Muchas regiones conjuntas son candidatas mixtas: alinean física y órbita, pero también heredan imputación y sesgo.

Auditoría de sesgo observacional

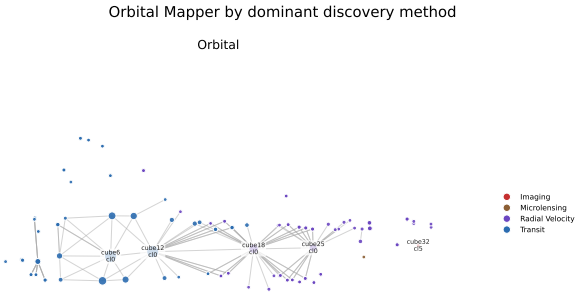

- `discoverymethod` no entra al Mapper.
- Se usa después como etiqueta externa.
- Permite saber si una región está dominada por tránsito, velocidad radial o imagen directa.
- El grafo orbital muestra asociación fuerte con método de descubrimiento.

Prueba nula por permutación

Hipótesis nula

Las etiquetas `discoverymethod` no están especialmente asociadas con la estructura Mapper.

- Se mantiene fijo el grafo.
- Se mantienen fijas las membresías de nodos.
- Se permutan las etiquetas `discoverymethod`.
- Corrida final: 1000 permutaciones.

Métrica orbital	Valor
Pureza observada	0.842
Pureza nula media	0.773
`purity_z`	26.630
NMI observado	0.254
NMI nulo medio	0.009
`nmi_p`	0.001

Síntesis final de regiones

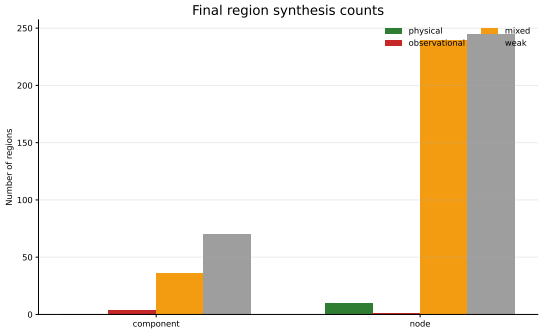

Etiqueta	Nodos	Componentes
`physical`	10	0
`observational`	1	4
`mixed`	240	36
`weak`	245	70

Lectura

Predominan regiones mixtas y débiles: la estructura existe, pero no es señal astrofísica limpia en bloque.

Mapa de evidencia

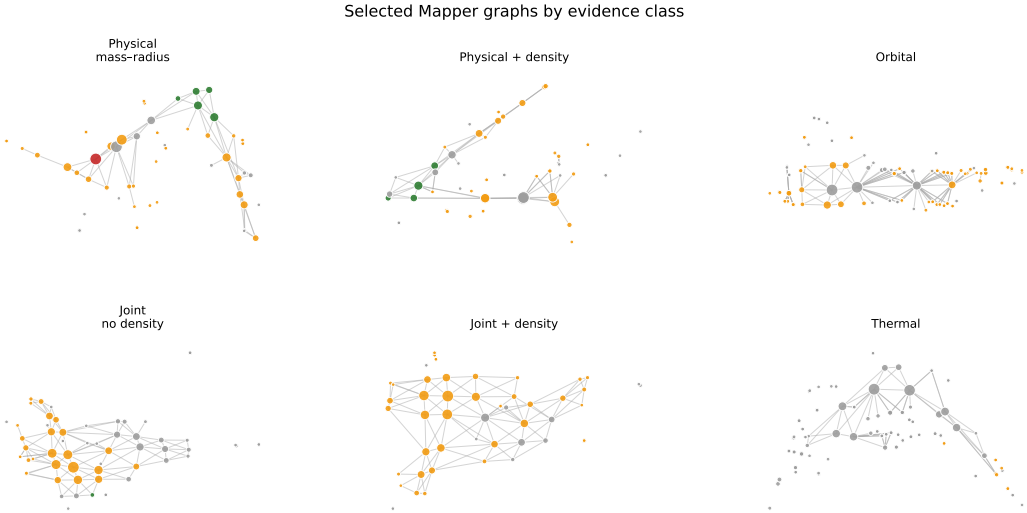

El orbital después de auditarlo

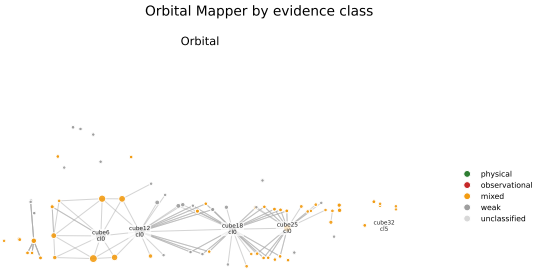

- Sigue siendo el grafo más informativo.
- Baja imputación: buen soporte de datos.
- Alta asociación con `discoverymethod`: lectura mixta.

Conclusión orbital

No queda invalidado, pero no debe venderse como estructura orbital pura.

Qué sí afirmamos / qué no afirmamos

Sí afirmamos

- Mapper encontró regiones estructuradas.
- El espacio orbital fue el candidato más informativo.
- La imputación y el sesgo cambian la interpretación.
- Hay regiones candidatas para inspección posterior.

No afirmamos

- Que descubrimos clases definitivas de exoplanetas.
- Que la topología observada es la topología real del universo.
- Que usar más variables siempre sería mejor.
- Que `discoverymethod` causa la estructura.

Conclusión

Conclusión defendible

Mapper/TDA es útil para construir una lectura topológica crítica del catálogo de exoplanetas, separando estructura astrofísica plausible de sesgo observacional e incertidumbre por imputación.

- El resultado más fuerte es orbital, por complejidad alta e imputación baja.
- La auditoría de sesgo impide sobreafirmarlo como señal física pura.
- La síntesis final convierte los grafos en un mapa de evidencia: regiones `physical`, `observational`, `mixed` y `weak`.

Backup: métricas estandarizadas

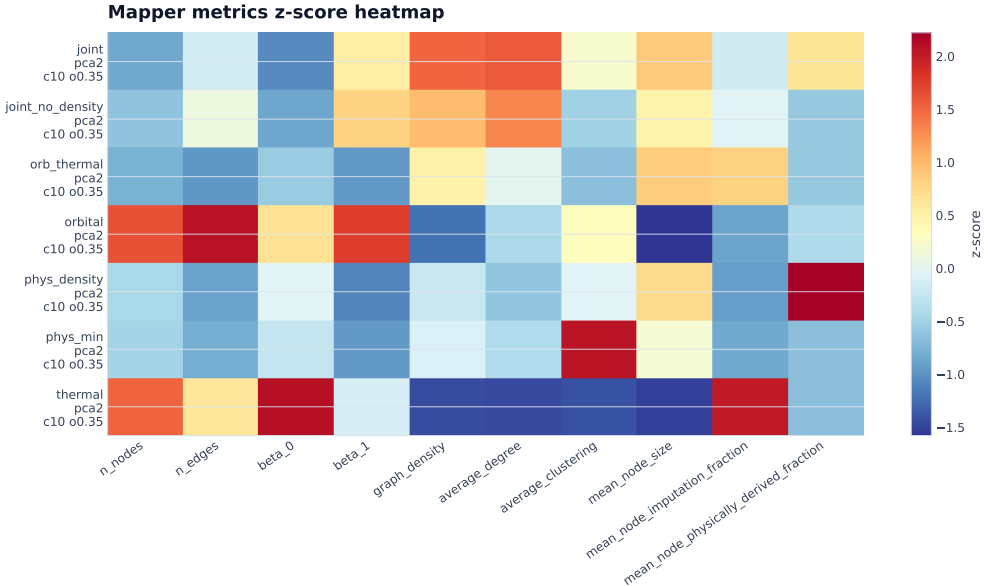

Backup: auditoría de imputación por configuración

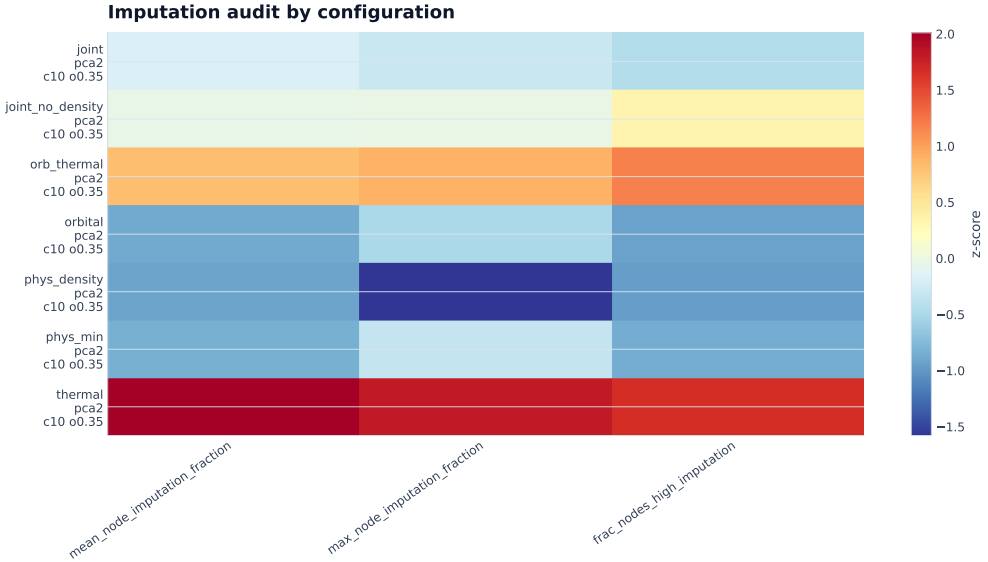
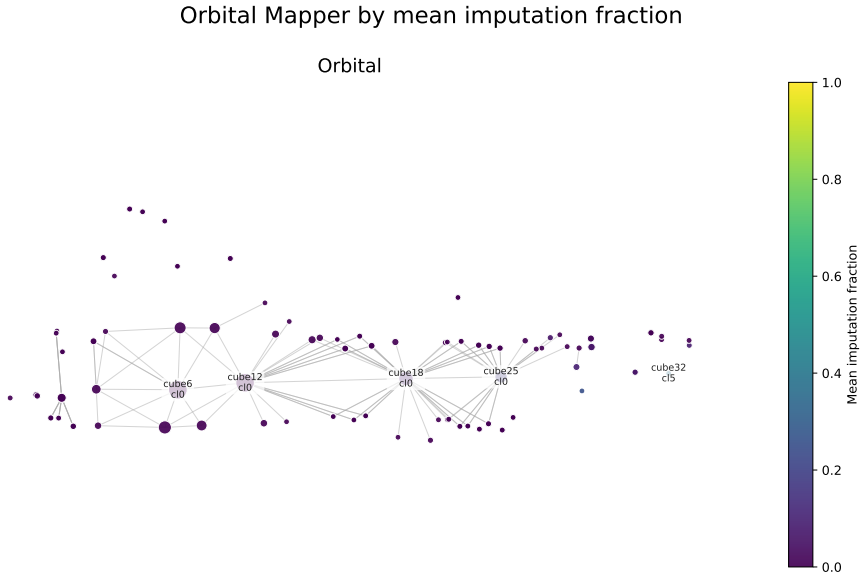
Backup: imputación orbital