EXODATA UDLAP

Topología del universo observable de exoplanetas

De sesgos de detección a regiones observacionalmente informativas

Tesis del proyecto

El catálogo NASA no representa el universo real de planetas. Representa el universo observable: lo que instrumentos, métodos e historia observacional han permitido registrar.

Fuente

NASA Exoplanet Archive – `PSCompPars`

6273 exoplanetas

Entrega técnica

Mapper/TDA

auditoría observacional

Shadow Score

TOI y ATI

gaps intra-sistema alrededor de estrellas

21 gráficas Mapper | PCA2 principal | DBSCAN local | ranking global y extensión a sistemas planetarios

Idea central: universo real vs universo observable

“No observamos todos los planetas.”

“Observamos los que podemos detectar.”

Problema científico

El catálogo mezcla señal astrofísica con límites instrumentales, geometría de detección, métodos de descubrimiento y selección humana de targets.

La pregunta no es solo qué planetas hay; es qué planetas logramos ver.

Metodología CRISP-DM

CRISP-DM 1–6. Del problema a comunicación

Business universo observable → **Data** NASA PSCompPars → **Preparation** log, scaling, imputación → **Modeling** Mapper/TDA → **Evaluation** topología + sesgo → **Communication** prioridades

1: catálogo

Construimos un mapa topológico global del universo observable.

2: regiones

Convertimos fronteras observacionales en TOI y ATI.

3: estrellas

Trasladamos la señal global a gaps orbitales dentro de sistemas conocidos.

El proyecto no termina en una gráfica: termina en preguntas observacionales accionables.

Datos y preparación

CRISP-DM 2–3. Data Understanding y Preparation

Variables planetarias

Bloques físico, orbital y térmico: masa, radio, densidad, período orbital, semieje mayor, insolación y temperatura de equilibrio.

Trazabilidad

Observado = medido. Derivado = calculado. Imputado = completado por el pipeline. La imputación preserva continuidad analítica, pero no agrega evidencia nueva.

Lectura prudente

No tratamos imputación y dato medido como equivalentes. Si un nodo depende mucho de imputación, la geometría puede mantenerse, pero baja su fuerza interpretativa.

Auditoría de datos

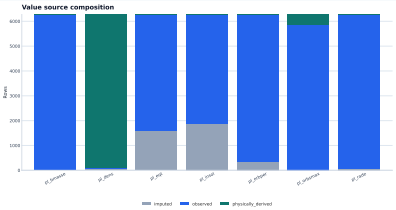

Metadata observacional

`discoverymethod`, año y facility se reservan para auditoría; no construyen directamente la geometría principal.

Espacios
7
físico, orbital, térmico y combinados

Estados
3
observado, derivado, imputado

Auditoría
externa
el sesgo no entra al lente

Regla
cautela
si sube imputación, baja confianza

Por qué Mapper como modelado no supervisado

CRISP-DM 4. Modeling

No impone clases fijas

No exige fijar cuántos grupos existen antes de mirar la geometría.

Conserva continuidad

Nos interesan transiciones, periferias y puentes, no solo clusters compactos.

Tolera geometrías complejas

Resume espacios no convexos y vecindarios que se superponen.

Es auditable

Cada nodo puede revisarse por método, imputación, tamaño y coherencia física local.

Especificación del experimento Mapper

$$7 \text{ espacios} \times 3 \text{ lentes} = 21 \text{ grafos}$$

Espacios: físico, orbital, térmico y combinados.

Lente principal: PCA2. Sensibilidad: `domain` y `density`.

Cover fijo: 10 cubos con `overlap = 0.35`. Clustering local: DBSCAN.

Lectura metodológica

Mapper funciona aquí como aprendizaje no supervisado orientado a forma: resume geometría y luego deja auditar si esa forma refleja estructura planetaria, sesgo observacional o mezcla de ambos.

Usamos Mapper para conservar forma observable, no para forzar una taxonomía cerrada.

Cómo funciona Mapper paso a paso

CRISP-DM 4. Modeling

1. Lente

PCA2 proyecta el espacio para observar gradientes globales.

2. Cover

Vecindarios solapados: 10 cubos y overlap 0.35.

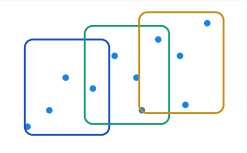

3. DBSCAN

Clustering local sin imponer un número fijo de grupos.

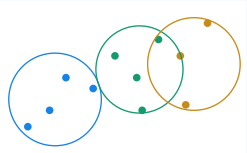

4. Grafo

Nodo = comunidad local. Arista = solapamiento de miembros.

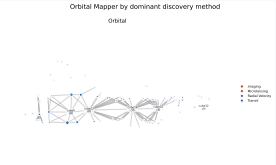

Mapper conserva continuidad, periferias y transiciones: justo lo que necesitamos para leer sesgo observacional.

Qué representa el grafo en esta historia

CRISP-DM 4. Modeling

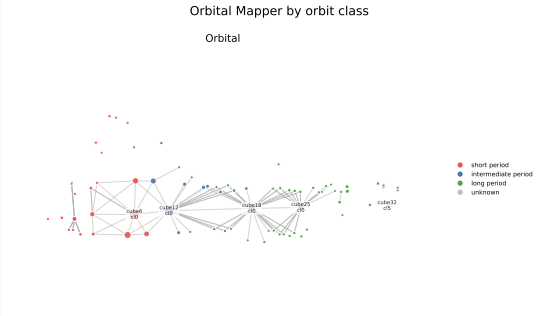

Nodo denso

Zona altamente observable o muy poblada dentro del catálogo.

Rama

Régimen especializado: puede mezclar física y método de detección.

Puente

Transición entre regímenes orbitales u observacionales.

Hueco

Baja cobertura relativa: candidato para inspección, no prueba de ausencia.

Conclusión intermedia: el Mapper orbital sí organiza sesgo observacional

CRISP-DM 5. Evaluation

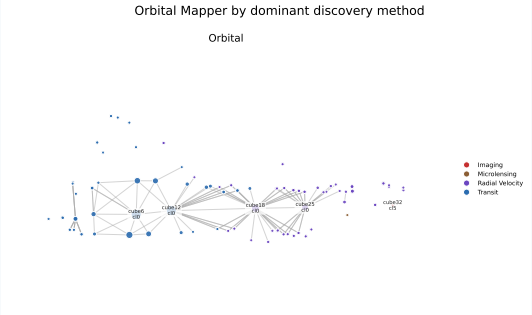

Lectura

El grafo orbital no solo organiza vecindades planetarias. También conserva información sobre cómo fueron descubiertos esos planetas.

NMI
0.165
nodo vs. método

z
138.9
muy lejos del nulo

p
0.001
asociación significativa

Conclusión

Existe sesgo observacional estructurado en los nodos del Mapper. Eso no invalida el mapa; explica por qué necesitamos auditarlo antes de priorizar.

Paso siguiente

Shadow Score, TOI y ATI convierten esa huella observacional en una prioridad local y regional interpretable.

Complejidad topológica del mapa: 124 nodos, 196 aristas, 96 ciclos independientes

CRISP-DM 5. Evaluation

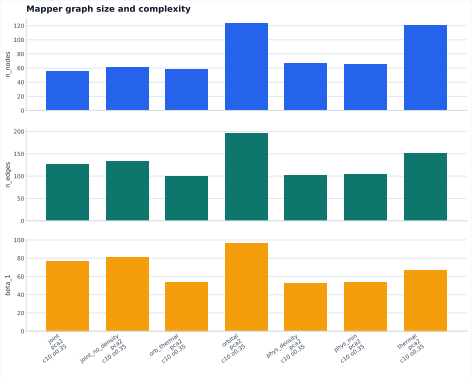

Lectura

No buscamos solo complejidad visual. Buscamos una geometría interpretable y metodológicamente defendible.

Métricas

Nodos, aristas y β_1 resumen riqueza topológica. La imputación media limita cuánto confiar en esa estructura.

Conclusión

El espacio orbital destaca porque conserva mucha estructura sin depender de imputación extensa.

Resultado global: el espacio orbital como mapa principal

CRISP-DM 5. Evaluation

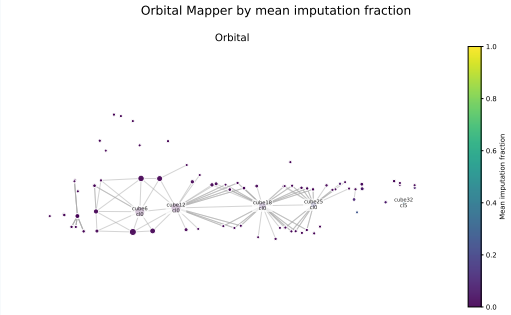

Por qué este mapa

Alta complejidad + baja imputación = mapa defendible del universo observable orbital. La estructura no descansa principalmente en completación artificial del catálogo y conserva trazabilidad razonable.

Nodos
124
comunidades locales

Aristas
196
continuidad topológica

β_1
96
ciclos independientes

Imputación
0.011
dependencia baja

Lectura prudente

Baja imputación no significa verdad definitiva. Significa que, dentro del pipeline, este mapa requiere poca completación relativa para sostener su geometría y por eso admite una lectura más fuerte.

Shadow Score: frontera observacional local

CRISP-DM 5–6. Evaluation y Communication

Shadow Score = índice local de frontera observacional

$$\mathrm{Shadow}(v) \propto f_{\mathrm{dom}}(v)(1 - H(v))(1 - I(v))B(v)S(v)$$

Crece cuando un nodo tiene método dominante, baja entropía, baja imputación, contraste con vecinos y soporte suficiente. Resume una frontera local de cobertura observacional.

Detecta

cambios locales en cobertura observacional dentro del grafo.

No detecta

planetas faltantes ni probabilidades físicas de ausencia.

Caso orbital

`cube17_cluster2`: RV dominante, n=8, imputación 0.000, Shadow = 0.274.

Caso poblacional

`cube51_cluster1`: Transit dominante, n=79, imputación 0.000, Shadow = 0.552.

De mapa global a prioridad: TOI y ATI

CRISP-DM 6. Deployment / Communication

Definición regional

$$\mathrm{TOI}(v) = \mathrm{Shadow}(v)(1 - I_{R^3}(v))C_{\mathrm{phys}}(v)S_{\mathrm{net}}(v)$$

Frontera observacional + baja imputación en R^3 + coherencia física local + soporte de red.

Definición por planeta ancla

$$\mathrm{ATI}(p^*) = \mathrm{TOI}(v)\Delta_{\mathrm{rel,best}}(p^*)(1 - I_{R^3}(p^*))A(p^*)$$

Convierte una región prioritaria en un caso local: déficit relativo, baja imputación y representatividad.

Top regiones por TOI

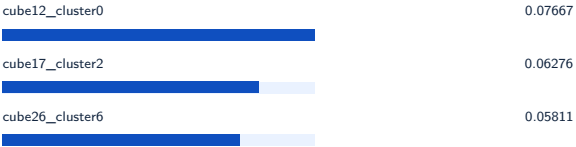

Top planetas ancla por ATI conservador

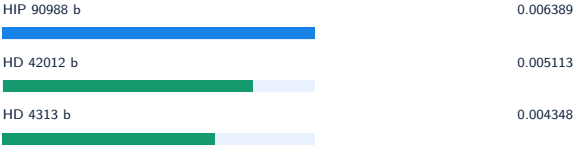

TOI prioriza nodos. ATI vuelve esa prioridad regional en un caso local auditable.

El siguiente salto: de regiones globales a estrellas conocidas

CRISP-DM 6. Deployment / Communication

Antes

El proyecto priorizaba regiones del catálogo completo: nodos, fronteras y planetas ancla.

Ahora

El módulo `11_stars` pregunta si esa señal global puede traducirse a intervalos orbitales dentro de sistemas planetarios conocidos.

Nuevas variables

Ahora trabajamos también con propiedades estelares: $M_\star$, $R_\star$, arquitectura del sistema y método dominante de descubrimiento.

Nueva unidad de salida

Una estrella, dos planetas observados, un gap orbital, una posición candidata y una razón plausible de dificultad observacional.

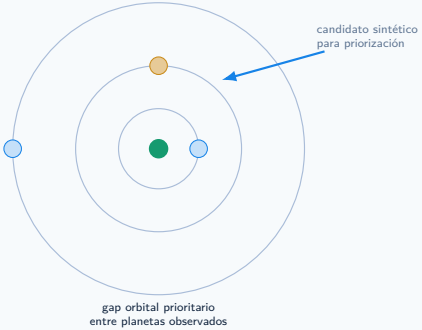

Modelo intra-sistema: gaps orbitales con herencia topológica

CRISP-DM 4–5. Modeling y Evaluation

Orden orbital observado

$$P_1 < P_2 < \cdots < P_n$$

P_i es el período orbital de cada planeta observado. Cada par adyacente define un gap orbital.

Interpolación prudente, no imputación del catálogo

$$\text{gap ratio} = \frac{P_{i+1}}{P_i}$$

Si el intervalo es amplio, insertamos una posición candidata en escala logarítmica de P y a. No imputamos un planeta real: interpolamos una ubicación plausible para priorizar seguimiento.

Herencia de la señal global

$$T_{\text{gap}} = \max\{\text{TOI}, \text{ATI}, \text{Shadow}\}_{\text{endpoints}}.$$

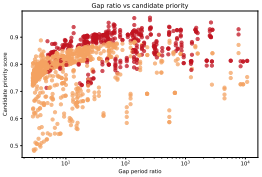

Un gap amplio no basta. La prioridad combina arquitectura, soporte topológico, análogos, detectabilidad y calidad de datos.

Detectabilidad relativa: por qué podría no haberse visto

CRISP-DM 5. Evaluation

Sistemas tipo tránsito

$$p_{\mathrm{tr}} \approx \frac{R_\star}{a^*} \qquad \delta \approx \left(\frac{R_p^*}{R_\star}\right)^2$$

Períodos más largos y menor probabilidad geométrica reducen oportunidades de detección.

Sistemas tipo velocidad radial

$$K_{\mathrm{proxy}} \propto \frac{M_p^*}{M_\star^{2/3}(P^*)^{1/3}}$$

Masas menores y períodos largos producen señales dinámicas más débiles.

Insumo estelar

$M_\star$ y $R_\star$ conectan el gap con detectabilidad.

Salida

Dificultad relativa comparada contra planetas observados del mismo sistema.

Cautela

Proxy operativo, no modelo instrumental completo.

La pregunta pasa de “dónde falta cobertura” a “por qué este intervalo pudo ser difícil de detectar”.

Casos finales

CRISP-DM 6. Deployment / Communication

Interpolación del candidato

Cada candidato nace dentro de un gap orbital entre dos planetas vecinos. Se interpola una posición en P y a, y luego se estiman masa, radio y detectabilidad relativa mediante análogos y propiedades estelares.

Score por sistema / candidato

$$\text{Priority} = 0.30\, S_{\text{gap}} + 0.25\, S_{\text{topo}} + 0.20\, S_{\text{analog}} + 0.15\, S_{\text{detect}} + 0.10\, S_{\text{quality}}$$

El ranking sube cuando el gap es amplio, la capa topológica previa es fuerte, existen análogos globales, la no detección resulta plausible y la calidad de datos del sistema acompaña.

Tres historias observacionales

WASP-132 — prioridad 0.972 | período largo

HD 27894 — prioridad 0.971 | señal RV débil

HAT-P-17 — prioridad 0.937 | señal RV débil

Lectura

Los tres casos heredan soporte topológico global y lo traducen a una pregunta concreta: qué intervalo orbital merece seguimiento futuro y por qué pudo haber quedado subobservado?

Sistema + intervalo + razón de dificultad.

WASP-132 como puente entre catálogo y sistema

CRISP-DM 6. Deployment / Communication

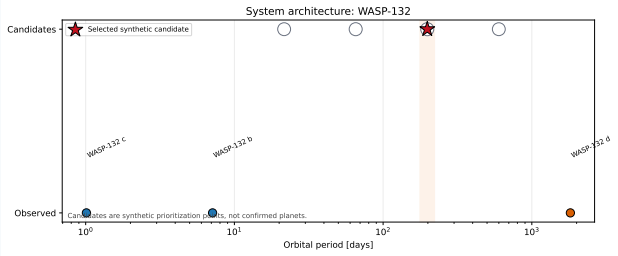

Cómo se obtuvo

Se ordena el sistema por período orbital, se mide el gap entre planetas vecinos y se inserta un candidato sintético en escala logarítmica de P y a. La prioridad final incorpora soporte por análogos globales y proxies de detectabilidad.

Intervalo

WASP-132 b – WASP-132 d

Candidato sintético

$P^* \approx 198.10$ días, $a^* \approx 0.615$ AU.

Por qué prioriza

Prioridad 0.972, score topológico 1.0, score del gap 0.975 y soporte por análogos.

Por qué pudo no verse

período largo: menor probabilidad geométrica de tránsito y ventana observacional más costosa.

Lo que entrega el sistema completo

CRISP-DM 6. Deployment / Communication

Mapa global

Grafo Mapper del universo observable: estructura, periferias y fronteras.

orbital_pca2 | baja imputación

Ranking regional

TOI y ATI priorizan regiones y planetas ancla con interpretación auditable.

TOI | ATI conservador

Ranking por sistema

El módulo de estrellas traduce la señal a gaps orbitales y detectabilidad.

WASP-132 | HD 27894

Datos NASA → Mapper → Shadow/TOI/ATI → Gaps por estrella → Seguimiento

El valor es la capacidad de decidir mejor dónde mirar.

Limitaciones y siguiente trabajo

CRISP-DM 5–6. Evaluation y Communication

Límites

No reconstruimos el universo completo ni confirmamos planetas faltantes.

Dependencias

Variables elegidas, imputación, parámetros Mapper, proxies de tránsito/RV y calidad de datos del sistema.

Sobre estrellas

Los candidatos intra-sistema son posiciones sintéticas de priorización, no posiciones confirmadas.

Siguiente paso 1

Injection-recovery por método de descubrimiento y por instrumento.

Siguiente paso 2

Funciones de completitud específicas por estrella, misión y campaña.

Siguiente paso 3

TESS, Kepler, Gaia, series RV, N-body e integración dinámica.

Cierre

El catálogo de exoplanetas no es el universo planetario.

Es la huella de cómo la humanidad lo ha observado.

Mapper/TDA permite cartografiar esa huella. TOI/ATI la convierten en prioridad regional. El módulo de estrellas la traduce a intervalos orbitales concretos para seguimiento futuro.

universo observable | priorización interpretable | sistemas estelares